# สรุปภาพรวมงาน: ระบบรวบรวมราคาการ์ด One Piece Card Game ชุด OP17 จากหลายแหล่ง

02739452 แพลตฟอร์มข้อมูลขนาดใหญ่และการวิเคราะห์ · สอบปลายภาค ภาคต้น 2569
ชื่อ ป้องเกียรติ หันกลาง รหัสนิสิต 6621650582 หมู่ 820 ลำดับที่ 3
GitHub: https://github.com/arm89400-hue/02739452-03-6621650582

## 1. ภาพรวมงานแต่ละส่วน

**หัวข้อ: ราคาการ์ด One Piece Card Game ชุดล่าสุดที่ทุกแหล่งมีข้อมูล คือ OP17 "The World's Strongest Warriors"**
**นำราคาจาก 3 เว็บมารวมเป็นชุดข้อมูลเดียว เพื่อเปรียบเทียบราคาการ์ดใบเดียวกันข้ามตลาด (ไม่มีข้อมูลส่วนบุคคล)**

| แหล่งข้อมูล | วิธีดึง | ข้อมูลที่ได้ |
|---|---|---|
| PriceCharting | Web scraping (requests + BeautifulSoup, ไม่ใช้ Selenium) robots.txt อนุญาต | ราคา Ungraded / Grade 9 / PSA 10 (USD) |
| Limitless TCG | Web scraping หน้า set + หน้าการ์ดทีละใบ (delay 0.7 วินาที) robots.txt อนุญาตทั้งหมด | ราคา USD + EUR ของแต่ละเวอร์ชันการ์ด |
| TCGplayer ผ่าน TCGCSV | JSON API (products + prices) ไม่ต้องใช้ key | Market price (USD), rarity, เลขการ์ด |

สถาปัตยกรรม: Docker Compose → Apache Airflow 2.10 (LocalExecutor) → PostgreSQL 16 → เว็บ dashboard Streamlit (อ่านจาก PostgreSQL โดยตรง)

DAG op17_card_prices: create_tables → TaskGroup extract (3 แหล่งรันขนาน) → TaskGroup transform (Dynamic Task Mapping) → load_upsert → quality_check (branch) → build_merged / quality_alert → record_run

| ระดับ | สิ่งที่ทำได้ | สถานะ |
|---|---|---|
| ระดับ 1 | DAG extract → transform → load ลง PostgreSQL, เว็บแสดงตารางและกราฟ | ✓ ครบ |
| ระดับ 2 | 3 แหล่งรันขนานใน TaskGroup, รวมเป็น schema เดียว, UPSERT (ON CONFLICT (source, source_key) DO UPDATE) รันซ้ำแล้วจำนวนแถวไม่เพิ่ม, เว็บมี KPI 5 ตัว และตัวกรอง (แหล่ง / เวอร์ชัน / ช่วงราคา / ค้นหา) | ✓ ครบ |
| ระดับ 3 | transform/load ใช้ trigger_rule=all_done → แหล่งใดล่มยังรวมแหล่งที่เหลือได้ (ทดสอบด้วย param simulate_down), ตัดรายการซ้ำข้ามแหล่งด้วยคีย์ (เลขการ์ด + เวอร์ชัน) ลงตาราง cards_merged, quality_check ตรวจ 5 ข้อ แล้ว branch ไป build_merged หรือ quality_alert | ✓ ครบ |
| โบนัส | หน้า Pipeline status บนเว็บ (สถานะทุก task, ผลตรวจคุณภาพ, ประวัติการรัน) และใช้ Dynamic Task Mapping | ✓ ทั้งสองอย่าง |

## 2. ปัญหาที่พบและวิธีแก้

| ปัญหา | อาการ | วิธีหาสาเหตุ | วิธีแก้ |
|---|---|---|---|
| 1. Airflow webserver เปิดไม่ขึ้น | เปิด localhost:8080 ได้ ERR_EMPTY_RESPONSE แม้ container สถานะ Up | docker compose logs airflow-webserver พบ "No response from gunicorn master within 120 seconds" แล้ว webserver ถูก restart วนซ้ำ (เครื่องช้า เปิด 4 workers + ติดตั้ง package ตอน start) | ตั้ง WEB_SERVER_MASTER_TIMEOUT=600, WORKERS=2, ไม่ให้ webserver ติดตั้ง package เพิ่ม แล้ว docker compose up -d --force-recreate airflow-webserver |
| 2. Limitless ไม่มีราคาในหน้ารวม | หน้า set ของ Limitless แสดงแค่ราคารวมทั้งชุด ไม่มีราคาการ์ดรายใบ | ตรวจโครงสร้างหน้าเว็บ พบว่าราคาอยู่ในหน้ารายละเอียดของการ์ดแต่ละใบ (USD/EUR แยกตามเวอร์ชัน) | ดึงลิงก์การ์ดจากหน้า set แล้ว scrape ทีละหน้า หน่วงเวลา 0.7 วินาทีเพื่อไม่ให้โหลดเว็บหนัก หน้าใดพลาดข้ามไป ไม่ทำให้ทั้งแหล่งล้ม |
| 3. ตัดรายการซ้ำข้ามแหล่งไม่ได้ | การ์ดใบเดียวกันจับคู่กันไม่ติด เพราะแต่ละเว็บเขียนเวอร์ชันต่างกัน | เทียบข้อมูลดิบ: PriceCharting ใช้ [Super Alternate Art], TCGplayer ใช้ (Alternate Art), Limitless ใช้ตัวย่อ aa / sp | ดึงเลขการ์ดด้วย regex (เช่น OP17-079) และสร้างฟังก์ชัน norm_variant แปลงเป็นรหัสกลาง NORMAL/ALT/SUPER_ALT/MANGA/SP แล้วใช้ (card_number, variant) เป็นคีย์ |
| 4. ชุดล่าสุด OP18 ไม่ครบทุกแหล่ง | หา OP18 ไม่เจอใน PriceCharting และ Limitless | ตรวจรายการชุดของทั้ง 3 เว็บ: OP18 มีแค่ใน TCGCSV | เลือก OP17 ซึ่งเป็นชุดล่าสุดที่ทั้ง 3 แหล่งมีข้อมูล เพื่อให้ตัดรายการซ้ำข้ามแหล่งได้จริง |

## 3. การวางแผนและจัดลำดับงาน

| ช่วงเวลา | งาน |
|---|---|
| 13:00–13:40 | อ่านโจทย์ เลือกหัวข้อ ตรวจแหล่งข้อมูล (robots.txt, ต้องไม่ใช้ Selenium, มีข้อมูล ≥ 100 รายการ) แล้วจองหัวข้อในไลน์ |
| 13:40–14:00 | เขียน DAG + ฟังก์ชัน extract/transform/load, docker-compose, dashboard แล้วทดสอบ DAG กับ PostgreSQL ก่อน push ขึ้น GitHub (commit แรก 13:55) |
| 14:00–14:50 | รันระบบด้วย Docker บนเครื่อง แก้ปัญหา webserver, ตรวจผลการดึงข้อมูลจริง |
| 14:50–15:20 | ย้ายไปเครื่องใหม่ (clone จาก GitHub + สร้าง .env) รัน DAG ทั้งแบบปกติและ simulate_down เก็บภาพหน้าจอ |
| 15:20–16:00 | เขียน PDF สรุป ตรวจ README และ commit สุดท้ายก่อน 16:00 |

หลักการจัดลำดับ: ทำระบบให้ครบทุกระดับแบบเรียบง่ายก่อน (end-to-end) แล้วค่อยแก้ปัญหาตอนรันจริง เลือกแหล่งที่เป็น HTML ธรรมดาหรือ API ฟรี เพื่อไม่เสียเวลากับเว็บที่ต้องใช้ JavaScript และ commit ขึ้น GitHub เร็วเพื่อกันงานหาย

งานที่ตัดออกและเหตุผล:

- เก็บประวัติราคาตามเวลา (price history): UPSERT จะเขียนทับราคาเดิม ถ้าจะเก็บต้องมีอีกตาราง และใน 3 ชั่วโมงมีข้อมูลแค่วันเดียว กราฟแนวโน้มจึงไม่มีความหมาย
- ร้านค้าไทย / เว็บ TCGplayer โดยตรง: หน้าเว็บโหลดด้วย JavaScript ต้องใช้ Selenium ซึ่งโจทย์ห้าม จึงใช้ TCGCSV (ข้อมูล TCGplayer แบบ JSON) แทน
- แจ้งเตือนผ่าน LINE/Email เมื่อ quality ไม่ผ่าน: ต้องมี token ภายนอก จึงทำเป็น task quality_alert ที่บันทึก log และแสดงผลบนหน้า Pipeline status แทน
- แปลงราคาเป็นเงินบาท: ต้องเพิ่มแหล่งอัตราแลกเปลี่ยนอีกตัว ไม่ใช่ประเด็นหลักของโจทย์ จึงแสดงเป็น USD/EUR ตามแหล่งเดิม